

Technische Dokumentation: Pokémon Emerald RL-Agent IT-Architektur und Systembeschreibung

Projektübersicht für Studenten

27. Dezember 2025

Inhaltsverzeichnis

| | | |
|----------|--|----------|
| 1 | Einführung | 2 |
| 2 | IT-Architektur | 2 |
| 2.1 | Schichtmodell | 2 |
| 3 | Modulbeschreibung: Wer macht was? | 2 |
| 4 | Funktionsweise des Codes | 2 |
| 4.1 | Der Trainingszyklus | 2 |
| 5 | Anleitung: System starten | 3 |
| 5.1 | Schritt 1: Vorbereitung | 3 |
| 5.2 | Schritt 2: Training/Ausführung starten | 3 |
| 5.3 | Schritt 3: Überwachung | 3 |
| 6 | Zusammenfassung | 4 |

1 Einführung

Dieses Projekt realisiert einen autonomen Agenten für das Spiel *Pokémon Emerald* (Gameboy Advance). Die technische Basis bildet das **Reinforcement Learning** (Bestärkendes Lernen), spezifisch der **PPO-Algorithmus** (Proximal Policy Optimization). Der Agent lernt durch Interaktion mit der Spielumgebung, Belohnungen zu maximieren.

2 IT-Architektur

Das System folgt einer klassischen Agent-Environment-Struktur, die jedoch für die Emulation optimiert wurde.

2.1 Schichtmodell

1. **Umgebungsschicht (Emulator):** Der *VisualBoyAdvance-M* Emulator führt die ROM (`temp_emerald.gba`) aus. Er dient als Blackbox, die Zustände (Frames/RAM) liefert.
2. **Schnittstellenschicht (Bridge):** Python-Skripte lesen den Speicherzustand (RAM) und den Grafikpuffer aus, um dem Agenten Informationen über KP, Position und Spielmenüs zu geben.
3. **Entscheidungsschicht (KI-Modell):** Ein tiefes neuronales Netzwerk (Deep Neural Network), das basierend auf dem aktuellen Zustand die Wahrscheinlichkeit für Aktionen (Steuerkreuz, Buttons) berechnet.
4. **Persistenzschicht (Datenbanken & Checkpoints):** Speicherung von Fortschritt, räumlichen Daten und Trainingsmetriken in SQLite-Datenbanken und ZIP-Dateien.

3 Modulbeschreibung: Wer macht was?

Das Projektverzeichnis ist modular aufgebaut. Jede Datei hat eine spezifische Aufgabe im Trainingszyklus:

4 Funktionsweise des Codes

4.1 Der Trainingszyklus

Beim Ausführen von `train.py` wird ein kontinuierlicher Loop gestartet:

- **Beobachtung (Observation):** Der Agent extrahiert Daten aus dem Spiel.
- **Aktion (Action):** Das Modell wählt einen Tastendruck (z.B. „RECHTS“).
- **Belohnung (Reward):** Das System evaluiert den Erfolg (z.B. Erfahrungspunkte gewonnen = positive Belohnung).
- **Optimierung:** Das Modell passt seine internen Gewichte an, um zukünftige Belohnungen zu erhöhen.

| Kategorie | Datei | Beschreibung |
|-----------|--------------------|---|
| Core | train.py | Das Hauptskript. Initialisiert die KI-Umgebung und startet die Trainingsschleife. |
| | pokemon_agend.py | Enthält die Definition des Agenten und der neuronalen Netzwerkarchitektur. |
| Memory | new_memory.py | Verwaltet das räumliche Gedächtnis (Speicherung von Gras, Wasser und POIs). |
| | ai_ppo_memory.json | Persistenter Kurzzeitspeicher für den PPO-Algorithmus. |
| Analyse | roi_test.py | Testet die „Region of Interest“-Erkennung (Screen-Scanning). |
| | analyze_battles.py | Wertet Kampflogs aus, um die Strategie-Effizienz zu prüfen. |
| Storage | pokemon_ai.db | Zentrale SQLite-Datenbank für Forschungs- und Agentendaten. |
| | cfg.json | Zentrale Konfiguration für Hyperparameter und Pfade. |

Tabelle 1: Übersicht der funktionalen Komponenten

5 Anleitung: System starten

Um das Projekt für eine Demonstration oder weiteres Training zu starten, folgen Sie diesen Schritten im Terminal:

5.1 Schritt 1: Vorbereitung

Stellen Sie sicher, dass die virtuelle Python-Umgebung aktiviert ist, um alle Abhängigkeiten (PyTorch, Stable-Baselines3) zu laden:

```
1 cd path/to/Gameboy
2 .\venv\Scripts\activate
```

5.2 Schritt 2: Training/Ausführung starten

Führen Sie das Trainingsskript aus. Dies lädt automatisch den letzten Checkpoint aus dem Ordner checkpoints/, falls vorhanden (*History Restored*):

```
1 python train.py
```

5.3 Schritt 3: Überwachung

Um die Lernkurve (FPS, Loss, Reward) in Echtzeit zu sehen, kann das Dashboard genutzt werden:

```
1 python dashboard.py
```

6 Zusammenfassung

Dieses System ist ein Beispiel für ein **End-to-End Reinforcement Learning Framework**. Durch die Trennung von Spiellogik (Emulator) und Entscheidungslogik (Python/-PyTorch) ist es hochgradig modular und ermöglicht es der KI, komplexe Aufgaben wie das Navigieren zu speziellen Orten (Gras/Wasser) durch Erfahrung zu lernen.